

תרגיל בית מספר 1

שם: נדב פיירמן שטרן

1. חוקר רוצה לבדוק האם סוג חנות הבגדים (סה"כ 4 סוגים) משפיע על המחיר הצפוי של הבגדים.

שמונה פריטי לבוש נדגמו באופן אקראי מכל חנות כדי לבחון את ההשערה.

את התוצאות ניתן למצוא בגיליון האלקטרוני של הבגדים בקובץ class.exe.01.

א. הציגו שני מודלים תיאורטיים - ANOVA ורגרסיה - ופרטו את מרכיביהם.

i. מודל ANOVA (ניתוח שונות חד-גורמי)

המודל מתאר את מחיר הפריט ה- j בחנות מסוג i :

$$Y_{ij} = \mu + \alpha_i + \epsilon_{ij}$$

$$i = 1, \dots, 4$$

$$j = 1, \dots, 8$$

מרכיבי המודל:

- μ – הממוצע הכללי של המחירים באוכלוסייה
- α_i – האפקט של סוג החנות i (הסטייה של ממוצע הקבוצה מהממוצע הכללי)
- ϵ_{ij} – טעות אקראית (רעש)

הנחות המודל:

- נורמליות – $\epsilon_{ij} \sim N(0, \sigma^2)$ לכל i, j
- שוויון שונויות – $\text{Var}(\epsilon_{ij}) = \sigma^2$ קבוע לכל הקבוצות
- אי-תלות – אין מתאם בין הטעויות ($\text{Cov} = 0$ לכל זוג תצפיות שונה)

אילוץ זיהוי:

$$\sum_{i=1}^4 \alpha_i = 0$$

ללא אילוץ זה המודל אינו מזוהה – קיימים אינסוף צירופים של μ ו α_i המניבים את אותם ערכים חזויים. האילוץ עוגן

את μ כממוצע הכללי האמיתי של האוכלוסייה.

ניתן לייצג את אותה בעיה באמצעות מודל רגרסיה המשתמש במשתני דמי לייצוג הקטגוריות השונות

$$Y_j = \beta_0 + \beta_1 X_{1j} + \beta_2 X_{2j} + \beta_3 X_{3j} + \epsilon_j$$

$$j = 1, \dots, 32$$

מרכיבי המודל:

- Y_j – מחיר הפריט בתצפית j
- β_0 – החותך, מייצג את ממוצע המחירים של חנות 4 (קבוצת הייחוס)
- X_{kj} – משתנה דמי המקבל את הערך 1 אם תצפית j שייכת לחנות k , ו 0 אחרת (עבור $k = 1, 2, 3$)
- β_k – מקדם הרגרסיה המייצג את הפרש המחיר הממוצע בין חנות k לחנות 4 (עבור $k = 1, 2, 3$)
- ϵ_j – מרכיב הטעות האקראית (שגיאה)

הנחות המודל:

- נורמליות – $\epsilon_j \sim N(0, \sigma^2)$ לכל j
- שוויון שונויות – $\text{Var}(\epsilon_j) = \sigma^2$ קבוע לכל הקבוצות
- עצמאות – $\text{Cov}(\epsilon_j, \epsilon_{j'}) = 0$ לכל $j \neq j'$

זיהוי המודל:

משתמשים ב $k - 1 = 3$ משתני דמי עבור 4 קבוצות. השמטת הקבוצה הרביעית מונעת תלות ליניארית מלאה ומאפשרת ל β_0 לייצג את ממוצע קבוצת הייחוס.

ב. כתבו השערה מתאימה לכל מודל וסיימו בציטוט סטטיסטיקת הבדיקה וערך p . הגיבו על הדמיון והשוני בין ההשערה למבחנים.

i. מודל ANOVA (ניתוח שונות)

השערות המבחן:

$$H_0: \alpha_1 = \alpha_2 = \alpha_3 = \alpha_4 = 0$$

$$H_1: \alpha_i \neq 0 \text{ לפחות אחד מהם שונה מ } 0$$

$$F = \frac{MS_B}{MS_W} \sim H_0 F(K - 1, N - K) = F(4 - 1, 32 - 4) = F(3, 28)$$

ii. מודל רגרסיה

השערות המבחן:

$$H_0: \beta_1 = \beta_2 = \beta_3 = 0$$

$$H_1: \beta_k \neq 0 \text{ לפחות אחד מהם שונה מ } 0$$

$$F = \frac{MS_{\text{reg}}}{MS_{\text{res}}} \sim H_0 F(K - 1, N - K) = F(4 - 1, 32 - 4) = F(3, 28)$$

iii. בדיקה סטטיסטית

	sum_sq	df	F	PR(>F)
C(type)	13508.8437	3.0000	217.2432	0.0000
Residual	580.3750	28.0000	NaN	NaN
F(3, 28) = 217.2432				
p-value = 1.72e-19				
Reject H0: True				

$$\alpha = 0.05$$

$$F_{s(3,28)} = 217.24$$

$$p - \text{value} = 1.72 \cdot 10^{-19}$$

מכיוון שערך $\alpha < p - \text{value}$ דוחים H_0 – קיים הבדל מובהק סטטיסטית בין ממוצעי המחירים של לפחות זוג אחד של חנויות

iv. דמיון והבדל

דמיון: אותו F ואותו p – value – המודלים שקולים.

שוני: ANOVA בודק שוויון כל הממוצעים, רגרסיה בודקת מול קבוצת ייחוס.

ג. חישוב ממוצעי המחירים לפי מקדמי הרגרסיה

ממודל הרגרסיה עם חנות 4 כקבוצת ייחוס, ממוצע כל חנות מחושב כך:

$$\widehat{\mu}_4 = \beta_0$$

$$\widehat{\mu}_1 = \beta_0 + \beta_1$$

$$\widehat{\mu}_2 = \beta_0 + \beta_2$$

$$\widehat{\mu}_3 = \beta_0 + \beta_3$$

כלומר, β_0 הוא ממוצע חנות הייחוס (חנות 4), וכל β_k מייצג את ההפרש בין חנות k לחנות 4.

Store 1: 96.0000
Store 2: 114.0000
Store 3: 123.8750
Store 4: 152.7500

חנות 1 – 96

חנות 2 – 114

חנות 3 – 123.875

חנות 4 – 152.75

ד. חישוב אפקטי הקבוצות

האפקט של כל קבוצה מוגדר כהסטייה של ממוצע הקבוצה מהממוצע הכללי:

$$\hat{\alpha}_i = \bar{Y}_i - \bar{Y}$$

כאשר $\bar{Y}$ הוא הממוצע הכללי של כלל התצפיות, ו $\bar{Y}_i$ הוא ממוצע החנות i שחושב בסעיף ג

שים לב כי בהתאם לאילוץ הזיהוי $\sum \alpha_i = 0$

Grand Mean: 121.6562
Store 1: effect = -25.6562
Store 2: effect = -7.6562
Store 3: effect = 2.2188
Store 4: effect = 31.0938
Sum of effects: 0.000000

$$\bar{Y} = 121.66$$

$$\hat{\alpha}_1 = 96 - 121.66 = -25.66$$

$$\hat{\alpha}_2 = 114 - 121.66 = -7.66$$

$$\hat{\alpha}_3 = 123.875 - 121.66 = 2.22$$

$$\hat{\alpha}_4 = 152.75 - 121.66 = 31.09$$

$$\sum \alpha_i = -25.66 - 7.66 + 2.22 + 31.09 \approx 0$$

2. נתון מודל

$$Y_i = \beta I\{X_i > c\} + \epsilon_i$$

$$i = 1, \dots, n$$

כאשר $c > 0$ והשגיאות מקיימות

○ נורמליות $\epsilon_i \sim N(0, \sigma^2)$ לכל i

○ שווי שונות $\text{Var}(\epsilon_i)$ קבוע

○ עצמאות $\text{Cov}(\epsilon_i, \epsilon_j) = 0$ לכל $i \neq j$

שים לב כי המודל אינו כולל חותך — יש פרמטר יחיד לאמוד β

א. גזירת אומדן OLS והשוואה ל MLE

כדי לאמוד את β במודל $Y_i = \beta I_i + \epsilon_i$, נבצע בשלוש שיטות

i. גזירה בצורה ישירה (Direct Form)

בשיטת הריבועים הפחותים (OLS), אנו מחפשים את הערך של β שמביא למינימום את סכום ריבועי השאריות (RSS)

$$S(\beta) = \sum_{i=1}^n (Y_i - \beta I_i)^2$$

נגזור לפי β ונשווה לאפס

$$\frac{dS}{d\beta} = -2 \sum_{i=1}^n I_i (Y_i - \beta I_i) = 0$$

נפתח את הסוגריים

$$\sum_{i=1}^n I_i Y_i - \beta \sum_{i=1}^n I_i^2 = 0$$

מאחר ו I_i הוא משתנה אינדיקטור (0 או 1), מתקיים $I_i^2 = I_i$, לכן $\sum I_i^2 = \sum I_i = n_c$, כאשר n_c הוא מספר התצפיות שעבורן $X_i > c$

$$\hat{\beta}_{OLS} = \frac{\sum_{i: X_i > c} Y_i}{n_c} = \bar{Y}_{X > c}$$

ii. גזירה בצורה מטריציונית (Matrix Form)

נכתוב את המודל כ $y = X\beta + \epsilon$ במודל שלנו ללא חותך, מטריצת העיצוב X היא וקטור עמודה יחיד המכיל את ערכי האינדיקטורים $\{I_1, \dots, I_n\}$ הנוסחה הכללית לאומדן OLS היא

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

$$X^T X = \sum_{i=1}^n I_i^2 = n_c \quad \bullet \quad \left(\frac{1}{n_c}\right) \text{ (סקלר, לכן ההופכי הוא } \frac{1}{n_c})$$

$$X^T y = \sum_{i=1}^n I_i Y_i = \sum_{i: X_i > c} Y_i \quad \bullet$$

$$\hat{\beta}_{OLS} = \frac{1}{n_c} \sum_{i: X_i > c} Y_i$$

תחת הנחת הנורמליות ($\epsilon_i \sim N(0, \sigma^2)$), פונקציית הנראות (Likelihood) היא

$$L(\beta) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{(Y_i - \beta I_i)^2}{2\sigma^2}}$$

נוח יותר למקסם את הלוגריתם של פונקציית הנראות (log-likelihood)

$$l(\beta) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - \beta I_i)^2$$

מקסום $l(\beta)$ שקול למזעור $\sum_{i=1}^n (Y_i - \beta I_i)^2$ שהוא בדיוק ה RSS של OLS. לכן אומדן ה MLE זהה לחלוטין לאומדן ה

OLS

$$\hat{\beta}_{MLE} = \hat{\beta}_{OLS} = \bar{Y}_{X>c}$$

ב. תוחלת ושונויות של האומדן

i. גזירה בצורה ישירה (Direct Form)

תוחלת האומדן

$$E[\hat{\beta}] = E\left[\frac{\sum_{i=1}^n I_i Y_i}{n_c}\right] = \frac{1}{n_c} \sum_{i=1}^n I_i E[Y_i]$$

נציב $E[Y_i] = \beta I_i$ מאחר ו $E[\epsilon_i] = 0$

$$E[\hat{\beta}] = \frac{\beta}{n_c} \sum_{i=1}^n I_i^2 = \frac{\beta \cdot n_c}{n_c} = \beta$$

האומדן חסר הטיה (Unbiased)

שונויות האומדן

$$\text{Var}(\hat{\beta}) = \text{Var}\left(\frac{\sum_{i=1}^n I_i Y_i}{n_c}\right) = \frac{1}{n_c^2} \sum_{i=1}^n I_i^2 \text{Var}(Y_i)$$

נציב $\sum_{i=1}^n I_i^2 = n_c$ ו $\text{Var}(Y_i)$

$$\text{Var}(\hat{\beta}) = \frac{\sigma^2 \cdot n_c}{n_c^2} = \frac{\sigma^2}{n_c}$$

ii. גזירה בצורה מטריצית (Matrix Form)

תוחלת האומדן

$$E[\hat{\beta}] = E[(X^T X)^{-1} X^T y] = (X^T X)^{-1} X^T E[y] = (X^T X)^{-1} X^T X \beta = \beta$$

שוונת האומדן

$$\text{Var}(\hat{\beta}) = (X^T X)^{-1} X^T \text{Var}(y) X (X^T X)^{-1}$$

מאחר ש $\text{Var}(y) = \sigma^2 I$

$$\text{Var}(\hat{\beta}) = \sigma^2 (X^T X)^{-1} = \frac{\sigma^2}{n_c}$$

$$E[\hat{\beta}] = \beta \quad \text{Var}(\hat{\beta}) = \frac{\sigma^2}{n_c}$$

ג. חישוב האומדן הנקודתי והשוונת המשוערת

נתונים

$$c = 2$$

$$x = (1, 0, -1, 3, 4, 5)$$

$$y = (10, 11, 12, 9, 10, 9)$$

i. בניית וקטור האינדיקטורים

לכל תצפית i הבדוק האם $x_i > c = 2$

I_i	$x_i > 2$	x_i	i
0	לא	1	1
0	לא	0	2
0	לא	-1	3
1	כן	3	4
1	כן	4	5
1	כן	5	6

$$n_c = \sum_{i=1}^6 I_i = 3$$

ii. חישוב האומדן הנקודתי

הצבה בנוסחה שגזרנו בסעיף א

$$\hat{\beta} = \frac{1}{n_c} \sum_{i: x_i > c} y_i = \frac{y_4 + y_5 + y_6}{3} = \frac{9 + 10 + 9}{3} = \frac{28}{3} \approx 9.333$$

iii. אמידת σ^2 מהשאריות

מאחר ש σ^2 אינו נתון בשאלה, נאמוד אותו מהשאריות

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n e_i^2}{n - p}$$

כאשר $p = 1$ (מספר הפרמטרים), $n - p = 5$ (דרגות החופש של השאריות), ו $\hat{y}_i = \hat{\beta} \cdot I_i$

e_i^2	e_i	$\hat{y}_i$	I_i	y_i	i
100	10	0	0	10	1
121	11	0	0	11	2
144	12	0	0	12	3
0.111	-0.333	9.333	1	9	4
0.444	0.667	9.333	1	10	5
0.111	-0.333	9.333	1	9	6

$$\sum e_i^2 = 365.67$$

$$\hat{\sigma}^2 = \frac{365.67}{5} \approx 73.13$$

iv. חישוב השונות המשוערת

הצבה בנוסחה שגזרנו בסעיף ב

$$\widehat{\text{Var}}(\hat{\beta}) = \frac{\hat{\sigma}^2}{n_c} = \frac{73.13}{3} \approx 24.38$$

$$\text{SD}(\hat{\beta}) = \sqrt{24.38} \approx 4.94$$

	Value
n_c	3.0000
$\hat{\beta}$	9.3333
$\hat{\sigma}^2$	73.1333
$\text{Var}(\hat{\beta})$	24.3778
$\text{SD}(\hat{\beta})$	4.9374

ד. בדיקת מובהקות המודל

i. השערות המבחן

$$H_0 : \beta = 0$$

$$H_1 : \beta \neq 0$$

תחת H_0 המשתנה $I\{X_i > c\}$ אינו תורם מידע לחיזוי של Y , כלומר הסף c אינו משפיע על התוחלת של Y

ii. סטטיסטי המבחן

מאחר ש σ^2 אינו נתון ונאמד מהמדגם, סטטיסטי המבחן מתפלג לפי התפלגות t של סטיוודנט

$$t_s = \frac{\hat{\beta} - 0}{\widehat{SD}(\hat{\beta})} \sim H_0 t_{(n-p)}$$

כאשר $n - p = 6 - 1 = 5$ הן דרגות החופש של השאריות

לו σ^2 היה ידוע, היינו משתמשים במבחן Z עם סטיית תקן מדויקת $\frac{\sigma}{\sqrt{n_c}}$ מאחר שאינו ידוע, הצבת האומדן $\hat{\sigma}$

במקום σ הופכת את ההתפלגות ל t (זנבות עבים יותר מ Z)

iii. חישוב הסטטיסטי

הצבה בערכים מסעיף ג

$$t_s = \frac{\hat{\beta}}{\widehat{SD}(\hat{\beta})} = \frac{9.333}{4.94} \approx 1.890$$

iv. חישוב ערך p וערך קריטי

במבחן דו-צדדי עם $df = 5$

$$t_c = t_{0.975,5} \approx 2.571$$

$$p - \text{value} = 2 \cdot P(T > 1.890) \approx 0.117$$

v. מסקנה

$$|t_s| = 1.890 < t_c = 2.571$$

$$p - \text{value} = 0.117 > \alpha = 0.05$$

מאחר שהסטטיסטי לא עבר את הערך הקריטי (וה $p - \text{value}$ גדול מ α) לא דוחים את H_0

	Value
t_s	1.8903
df	5
$t_c (\alpha=0.05)$	2.5706
p-value	0.1173
Reject H_0 ?	False

ה. רווח סמך 95%

i. הנוסחה

מאחר ש σ^2 אינו ידוע, רווח הסמך מבוסס על התפלגות t

$$\hat{\beta} \pm t_{1-\frac{\alpha}{2}, n-p} \cdot \widehat{SD}(\hat{\beta})$$

עבור $\alpha = 0.05$ ו $df = n - p = 5$ הערך הקריטי הוא $t_c = t_{0.975,5} \approx 2.571$ (זהה ל t_c מסעיף ד)

ii. חישוב הגבולות

$$L = \hat{\beta} - t_{1-\frac{\alpha}{2}, n-p} \cdot \widehat{SD}(\hat{\beta}) = 9.333 - 2.571 \cdot 4.94 = -3.359$$

$$U = \hat{\beta} + t_{1-\frac{\alpha}{2}, n-p} \cdot \widehat{SD}(\hat{\beta}) = 9.333 + 2.571 \cdot 4.94 = 22.025$$

iii. תוצאה

$$\beta \in [-3.359, 22.025]$$

רווח הסמך כולל את האפס, בעקביות עם המסקנה בסעיף ד שבו לא דחינו את $H_0 : \beta = 0$

Lower (2.5%)	$\hat{\beta}$ (point)	Upper (97.5%)
-3.3586	9.3333	22.0253

ו. חזרה על החישובים ב-Python

נריץ את המודל $Y_i = \beta I\{X_i > c\} + \epsilon_i$ באמצעות הפונקציה `smf.ols` של `statsmodels`, ונשווה את התוצאות

לחישובים הידניים מסעיפים ג-ה

i. הגדרת המודל והרצתו

נגדיר את המודל באמצעות נוסחה: $y \sim \text{ind} - 1$ כאשר `ind` הוא וקטור האינדיקטורים. ה-1 נוסחה אומר ל-

`statsmodels` לכלול חותך, בהתאם למודל שלנו.

OLS Regression Results						
Dep. Variable:	y	R-squared (uncentered):	0.417			
Model:	OLS	Adj. R-squared (uncentered):	0.300			
Method:	Least Squares	F-statistic:	3.573			
Date:	Sat, 18 Apr 2026	Prob (F-statistic):	0.117			
Time:	00:21:24	Log-Likelihood:	-20.844			
No. Observations:	6	AIC:	43.69			
Df Residuals:	5	BIC:	43.48			
Df Model:	1					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
ind	9.3333	4.937	1.890	0.117	-3.359	22.025
Omnibus:	nan		Durbin-Watson:		0.427	
Prob(Omnibus):	nan		Jarque-Bera (JB):		0.945	
Skew:	0.022		Prob(JB):		0.623	
Kurtosis:	1.056		Cond. No.		1.00	

ii. השוואה בין החישוב הידני ל statsmodels

נציג טבלה המשווה את הערכים שחישבנו ידנית בסעיפים ג-ה לערכים ש statsmodels מפיק:

	Manual	statsmodels
β	9.3333	9.3333
$SD(\beta)$	4.9374	4.9374
t_s	1.8903	1.8903
p-value	0.1173	0.1173
CI low	-3.3586	-3.3586
CI high	22.0253	22.0253

iii. דמיון והבדלים

דמיון:

- כל הערכים זהים לחלוטין בין החישוב הידני ל statsmodels. זה לא במקרה — הכלי מיישם את אותן נוסחאות $(X^T X)^{-1} X^T y$ שגזרנו ידנית בסעיפים א-ב
- ה statsmodels אומד את σ^2 בדיוק כמו שעשינו (מחלוקה ב $n - p$), מחשב את סטיית התקן, את סטטיסטי t , את ה $p - value$ — כולם עם אותה מתודולוגיה

הבדלים:

- נוחות: ב statsmodels כל התהליך מתבצע בשורה אחת `(smf.ols('y ~ ind - 1', data = df).fit())`. בחישוב הידני נדרשו מספר שלבים: חישוב שאריות, אמידת σ^2 , הצבה בנוסחת t , מציאת ערך קריטי, וכו
- שליטה: בחישוב הידני אנחנו רואים כל שלב, מה שמאפשר הבנה עמוקה יותר ואבחון שגיאות
- R^2 בפלט: שים לב ש statsmodels מציג R^2 (uncentered) במקום R^2 רגיל, כי המודל אינו כולל חותך. זו אינדיקציה חשובה שהמודל שלנו חריג — אין לפרש את הערך הזה כ"אחוז השונות המוסברת" במובן הקלאסי

מסקנה:

- החישוב הידני וה statsmodels ותנים אותן תוצאות בדיוק. היתרון של הכלי האוטומטי הוא מהירות ונוחות, והיתרון של החישוב הידני הוא הבנה של מה קורה "מתחת למכסה".

3. מנהל תיקי השקעות רוצה לבדוק האם ישנם הבדלים בתשואה השנתית הצפויה בתיקי השקעות באסטרטגיות השקעה שונות (A, B, C, D). הנתונים נמצאים ב-class.exe.01, גיליון בשם invest.

א. בדיקה ויזואלית של נורמליות

נבדוק האם התשואות של כל אסטרטגיה מפולגות בקירוב נורמלי. נעשה זאת בשני אופנים:

i. היסטוגרמה לכל קבוצה עם עקומת נורמלית מונחת – בדיקה ויזואלית

ii. מבחן Shapiro-Wilk לכל קבוצה – מבחן סטטיסטי פורמלי לנורמליות

i. לכל קבוצה – מבחן סטטיסטי פורמלי לנורמליות


נציג סיכום כללי של התשואות בכל אסטרטגיה

channel	count	mean	std	min	max
A	19	84.4249	40.9474	2.9895	139.0417
B	20	39.2327	23.9012	2.2268	74.5364
C	21	33.1254	17.7803	3.4658	58.4592
D	21	57.8373	35.3998	2.6376	109.7957

ii. היסטוגרמות עם עקומת נורמלית

לכל אסטרטגיה נצייר היסטוגרמה של התשואות ומעליה עקומת נורמלית המתאימה לממוצע ולסטיית התקן של

הקבוצה. אם ההתפלגות נורמלית, ההיסטוגרמה צריכה להצמד לעקומה



מבחן פורמלי לנורמליות, עם ההשערות

הנתונים מתפלגים נורמלית: H_0

הנתונים אינם נורמלים: H_1

דוחים את H_0 אם $p - \text{value} < 0.05$

Strategy	W	p-value	Normal?
A	0.9387	0.2497	True
B	0.9320	0.1689	True
C	0.9315	0.1475	True
D	0.9322	0.1523	True

מסקנה .iv

הבדיקה היוזואלית מראה שההתפלגויות בכל ארבע האסטרטגיות אינן נראות נורמליות:

- אסטרטגיה A: התפלגות דו-שיאית עם שיא סביב 50-60 ושיא נוסף סביב 100-140
 - אסטרטגיה B: התפלגות שטוחה, קרובה להתפלגות אחידה יותר מאשר לפעמון
 - אסטרטגיה C: קרובה יחסית לנורמלי עם שיא מרכזי אך זנבות לא סימטריים
 - אסטרטגיה D: התפלגות דו-שיאית עם שיאים סביב 15 וסביב 100
- מבחן Shapiro-Wilk לא דוחה נורמליות באף אחת מהקבוצות ($p > 0.05$ לכולן), אך יש לקחת תוצאה זו בזהירות:

- גודל המדגם בכל קבוצה קטן יחסית ($n \approx 20$), ולכן כוח המבחן לדחות נורמליות נמוך.
 - ההיסטוגרמות מראות בבירור סטיות מנורמליות, גם אם המבחן הפורמלי לא דוחה
- מסקנה: יש ספק ממשי לגבי מידת הנורמליות של ההתפלגויות. נמשיך עם ה ANOVA הפרמטרי בסעיף ב, ובסעיף ד נבחן האם כדאי גישה אי-פרמטרית

i. המודל התיאורטי

$$Y_{ij} = \mu + \tau_j + \epsilon_{ij}$$

$$j \in \{A, B, C, D\}$$

$$i = 1, \dots, n_j$$

מרכיבי המודל:

- Y_{ij} התשואה של תצפית i באסטרטגיה j
- μ הממוצע הכללי של התשואות באוכלוסייה
- τ_j אפקט אסטרטגיה j (סטייה מהממוצע הכללי)
- ϵ_{ij} טעות אקראית

הנחות המודל:

- נורמליות $\epsilon_{ij} \sim N(0, \sigma^2)$
- שוויון שוניות $\text{Var}(\epsilon_{ij}) = \sigma^2$ קבוע בכל הקבוצות
- אי-תלות $\text{Cov}(\epsilon_{ij}, \epsilon_{kl}) = 0$ עבור תצפיות שונות
- אילוך זיהוי: $\sum n_j \tau_j = 0$

ii. השערות המבחן

$$H_0 : \mu_A = \mu_B = \mu_C = \mu_D$$

H_0 : לפחות זוג אחד של תוחלות שונה

iii. סטטיסטי המבחן

$$F = \frac{MS_B}{MS_W} \sim H_0 F(k-1, N-k) = F(3,77)$$

כאשר $k = 4$ הוא מספר הקבוצות ו $N = 81$ הוא סך התצפיות

	sum_sq	df	F	PR(>F)
C(channel)	31339.6155	3.0000	11.1072	0.0000
Residual	72420.2209	77.0000	NaN	NaN

נציג את ה summary המלא של המודל הכולל גם את המקדמים (נשתמש בהם בסעיף ג לפוסט-הוק)

OLS Regression Results						
Dep. Variable:	Q("return")		R-squared:	0.302		
Model:	OLS		Adj. R-squared:	0.275		
Method:	Least Squares		F-statistic:	11.11		
Date:	Sat, 18 Apr 2026		Prob (F-statistic):	3.88e-06		
Time:	09:48:31		Log-Likelihood:	-390.16		
No. Observations:	81		AIC:	788.3		
Df Residuals:	77		BIC:	797.9		
Dep. Variable:	Q("return")		R-squared:	0.302		
Df Model:	3					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	84.4249	7.036	11.999	0.000	70.415	98.435
C(channel)[T.B]	-45.1922	9.825	-4.600	0.000	-64.756	-25.628
C(channel)[T.C]	-51.2994	9.710	-5.283	0.000	-70.635	-31.964
C(channel)[T.D]	-26.5875	9.710	-2.738	0.008	-45.923	-7.252
Omnibus:	1.570		Durbin-Watson:	1.689		
Prob(Omnibus):	0.456		Jarque-Bera (JB):	1.371		
Skew:	-0.165		Prob(JB):	0.504		
Kurtosis:	2.455		Cond. No.	4.93		

v. מסקנה

$$F \approx 11.11$$

$$p - \text{value} \approx 3.9 \cdot 10^{-6}$$

מאחר ש $p - \text{value} \ll 0.05$ דוחים את H_0 קיים הבדל מובהק סטטיסטית בתוחלות התשואה בין לפחות שתי אסטרטגיות

$R^2 \approx 0.302$ כלומר, האסטרטגיה מסבירה כ 30% מהשונות בתשואות. המסקנה הבאה היא לבדוק בין אילו זוגות קיים הבדל מובהק — זה מה שנעשה בסעיף ג

ג. פוסט-הוק עם Bonferroni, Fisher LSD, FDR

בסעיף ב דחינו את H_0 הכללית — יש הבדל בין התוחלות. עתה נבדוק בין אילו זוגות של אסטרטגיות קיים הבדל

מובהק. עם 4 קבוצות יש $\binom{4}{2} = 6$ השוואות זוגיות

אילו היינו בודקים כל השוואה ברמת מובהקות $\alpha = 0.05$ ללא תיקון, הסיכוי לדחות לפחות השערה אחת מטעות (FWER) היה:

$$1 - (1 - 0.05)^6 \approx 0.26$$

כלומר 26% — גבוה מדי. לכן נבצע שלושה סוגי תיקונים:

- Fisher's LSD: t-test רגיל עם שונות מאוחדת מה ANOVA, ללא תיקון. חזק אך לא שולט ב FWER
- Bonferroni: מחלקים את. הקלד משוואה כאן במספר ההשוואות $(\alpha_c = \frac{\alpha}{m})$. שומר על FWER אך שמרני

במיוחד

- FDR (Benjamini-Hochberg): שולט בפרופורציה הצפויה של גילויים שגויים מכל הדחיות. ביניים בין LSD ל-

Bonferroni

Pair	LSD p-value	Bonferroni	FDR (BH)	LSD reject	Bonf reject	FDR reject
A vs B	0.0001	0.0009	0.0004	True	True	True
A vs C	0.0000	0.0000	0.0000	True	True	True
A vs D	0.0338	0.2027	0.0507	True	False	False
B vs C	0.3574	1.0000	0.3574	False	False	False
B vs D	0.0569	0.3414	0.0683	False	False	False
C vs D	0.0067	0.0403	0.0134	True	True	True

i. סיכום הממצאים

ניתן לחלק את 6 הזוגות לשלוש קבוצות:

- מובהקים בכל שלוש השיטות A vs B, A vs C, C vs D: הבדלים חזקים שיתקיימו תחת כל תיקון.
- מובהקים רק ב LSD זה A vs D ($P_{LSD} \approx 0.0338$) נדחה רק בשיטה הליברלית, לא שורד את Bonferroni או FDR.

- לא מובהקים בכל השיטות: B vs C, B vs D אין עדות להבדל.

ii. השוואה בין השיטות

- Fisher LSD — הכי ליברלי. דוחה 4 זוגות (A-B, A-C, A-D, C-D). ללא הגנה על FWER.
- Bonferroni — הכי שמרני. דוחה רק 3 זוגות (A-B, A-C, C-D). ערכי ה-p מוכפלים ב-6.
- FDR (BH) — ביניים. גם דוחה 3 זוגות, אבל עם ערכי p נמוכים יותר מאלה של Bonferroni (כלומר יותר כוח להבחין).

ההבדלים המובהקים העיקריים הם בין אסטרטגיה A (הגבוהה) לבין B ו C (הנמוכות), ובין C ל D. הזוג A-D "חי על הגבול" — מובהק בשיטה הליברלית אך לא בשמרנית. הבחירה בין השיטות תלויה בהקשר: אם חשוב מאוד לא לדחות בטעות, נשתמש ב Bonferroni. אם הניסוי הוא חקרי עם הרבה השוואות, FDR מתאים יותר.

ד. התאמת המודל הנורמלי וגישה חלופית

i. האם המודל הנורמלי התאים?

לדעתנו המודל הפרמטרי הנורמלי אינו מתאים לנתונים. שלוש סיבות מרכזיות:

- נורמליות מופרת: מההיסטוגרמות בסעיף א ראינו שההתפלגויות אינן פעמון A ו D-זו-שיאיות, B קרובה לאחידה, רק C מזכירה נורמלי. מבחן Shapiro-Wilk לא דחה נורמליות, אך עם מדגם של $n \approx 20$ לכוך המבחן אין יכולת ממשית לדחות גם כשההפרה קיימת.
- שוויון שונויות מופר: סטיות התקן שונות מהותית בין הקבוצות ($std_A \approx 41$ לעומת $std_C \approx 18$). היחס הוא מעל 2, שזו אינדיקציה ברורה להפרת ההנחה.
- אופי הנתונים: תשואות פיננסיות נוטות להיות לא נורמליות מעצם טבען — זנבות כבדים, אסימטריה, ותצפיות חריגות הן מאפיין מובהק.

ii. גישה חלופית — אי-פרמטרית

- נעבור למבחנים המבוססים על דרגות של התצפיות במקום הערכים עצמם. שיטה זו עמידה מול הפרות של נורמליות ושוויון שונויות.
- Kruskal-Wallis – חלופה ל ANOVA חד-כיווני. בודק האם ההתפלגויות של כל הקבוצות זהות, מבוסס על סכומי דרגות.
 - Mann-Whitney U – חלופה ל t-test זוגי, לפוסט-הוק. עם תיקוני Bonferroni ו FDR לערכי p.
- הנחה יחידה: אי-תלות של התצפיות. אין צורך בנורמליות או בשוויון שונויות.

השערות המבחן:

$$H_0 : F_A = F_B = F_C = F_D$$

H_1 : לפחות אחת מההתפלגויות שונה

סטטיסטי המבחן מתפלג בקירוב $\chi^2_{(k-1)} = \chi^2_{(3)}$ תחת H_0

	Value
Kruskal-Wallis H	19.5815
p-value	0.0002
Reject H_0 ?	True

iv. פוסט-הוק + Mann-Whitney: תיקונים

נריץ Mann-Whitney לכל אחד מ-6 הזוגות, ונחיל את תיקוני Bonferroni ו FDR לערכי p

Pair	MW p-value	Bonferroni	FDR	MW rej	Bonf rej	FDR rej
A vs B	0.0009	0.0052	0.0026	True	True	True
A vs C	0.0001	0.0005	0.0005	True	True	True
A vs D	0.0396	0.2373	0.0593	True	False	False
B vs C	0.3966	1.0000	0.3966	False	False	False
B vs D	0.1087	0.6522	0.1304	False	False	False
C vs D	0.0286	0.1718	0.0573	True	False	False

v. השוואה למסקנות הפרמטריות ומסקנה סופית

תוצאות Kruskal-Wallis ($H \approx 19.58$, $p \approx 2 \cdot 10^{-4}$) מאשרות את מסקנת ה-ANOVA קיים הבדל מובהק בין התפלגויות התשואה של האסטרטגיות.

גם הפוסט-הוק האי-פרמטרי מוביל לאותם ממצאים כמו הפרמטרי:

- הזוגות A-B ו-A-C מובהקים בכל השיטות.
- הזוג A-D על הגבול (כמו בניתוח הפרמטרי).
- B-C ו-B-D לא מובהקים.

מסקנה סופית: למרות שהמודל הנורמלי הפרמטרי לא אידיאלי לנתונים הללו, שני הניתוחים (פרמטרי ואי-פרמטרי) מובילים לאותן מסקנות מהותיות. זה מחזק את אמינות הממצאים — הם יציבים ולא תלויים בבחירת השיטה הסטטיסטית. בדיווח מדעי רצוי להציג את שני הניתוחים; אם יש פער ביניהם, יש להעדיף את הניתוח האי-פרמטרי שאינו תלוי בהנחות שהופרו.

4. השתמשו בקובץ rats.csv קובץ זה מכיל נתונים מניסוי טוקסיקולוגי על עכברים.

48 העכברים חולקו באופן אקראי לקבל שלושה סוגי רעלים (I, II, III) וארבע קבוצות טיפול (A, B, C, D).

המשתנה התלוי הוא זמן התגובה לגירוי נתון.

א. איזון הניסוי Box-Plots

i. בדיקת איזון

ניסוי מאוזן הוא ניסוי שבו יש מספר שווה של תצפיות בכל שילוב של רמות (תא). בנתונים שלנו יש $3 \cdot 4 = 12$

תאים ו 48 עכברים, כך שאם הניסוי מאוזן יהיו $\frac{48}{12} = 4$ תצפיות בכל תא.

נציג את ספירות התצפיות בטבלת צלבים:


Poison / Treat	A	B	C	D
I	4	4	4	4
II	4	4	4	4
III	4	4	4	4



כפי שניתן לראות, יש בדיוק 4 תצפיות בכל אחד מ-12 התאים. הניסוי מאוזן לחלוטין.

ii. תרשימי תיבות (Box-Plots)

נצייר שלושה גרפים:

- זמן תגובה לפי רעל (מתעלם מהטיפול) — השפעת הרעל.
- זמן תגובה לפי טיפול (מתעלם מהרעל) — השפעת הטיפול.
- זמן תגובה לפי שילוב של שניהם — מאפשר לזהות אינטראקציה.





השפעת רעל:

- קיימת מגמה מונוטונית יורדת — Poison I נותן את זמני התגובה הגבוהים ביותר, ואחריו II ולבסוף III.
 - ניתן להסיק שרעל III הוא ה"מהיר" או ה"חזק" ביותר מבחינת זמן התגובה שהוא מייצר.
- השפעת טיפול:

- טיפולים B ו-D מניבים זמני תגובה ארוכים יחסית.
- טיפולים A ו-C מניבים זמנים קצרים יותר.

הערה חשובה לגבי הנחות המודל:

- מהגרף המשולב רואים שהשונויות גדלה עם הממוצע — קבוצות עם זמן תגובה גבוה (למשל Poison I + Treatment B) מציגות פיזור גדול יותר מקבוצות עם זמן נמוך (למשל Poison III + Treatment A).
- זוהי Heteroscedasticity — הפרה של הנחת שוויון השונויות שמבחן ANOVA מניח. נחזור לנקודה זו בסעיף ו' שבו נבחן את הנחות המודל גרפית.

ב. המודל התיאורטי של ANOVA דו-כיווני

נשתמש במודל ANOVA דו-כיווני ללא אינטראקציה (כפי שנדרש בסעיף ג):

$$y_{ijk} = \mu + \alpha_i + \beta_j + \epsilon_{ijk}$$

כאשר:

- $i = 1, 2, 3$ רמת הרעל (I, II, III)
- $j = 1, 2, 3, 4$ רמת הטיפול (A, B, C, D)
- $k = 1, 2, 3, 4$ מספר החזרה בתוך התא

מרכיבי המודל:

- y_{ijk} זמן התגובה של עכבר k בתא (רעל i, טיפול j)
- μ הממוצע הכללי של זמני התגובה באוכלוסייה
- α_i אפקט עיקרי של רעל i (סטייה מהממוצע הכללי)
- β_j אפקט עיקרי של טיפול j (סטייה מהממוצע הכללי)
- ϵ_{ijk} טעות אקראית

אילוצי זיהוי:

$$\sum_{i=1}^3 \alpha_i = 0$$

$$\sum_{j=1}^4 \beta_j = 0$$

הנחות המודל:

- נורמליות $\epsilon_{ijk} \sim N(0, \sigma^2)$
 - שוויון שונות $\text{Var}(\epsilon_{ijk}) = \sigma^2$ קבוע בכל 12 התאים
 - אי-תלות $\text{Cov}(\epsilon_{ijk}, \epsilon_{i'j'k'})$ עבור תצפיות שונות
 - אדיטיביות (אי-אינטראקציה) האפקט של רעל קבוע בכל רמות הטיפול ולהפך
- ג. אמידת מודל ה-ANOVA הדו-כיווני
- i. השערות המבחן
- במודל דו-כיווני בודקים שתי השערות נפרדות – אחת לכל גורם.
- עבור רעל:

$$H_0^{(1)}: \alpha_1 = \alpha_2 = \alpha_3 = 0$$

$H_1^{(1)}$: לפחות אחד מה α_i שונה מאפס:

עבור טיפול:

$$H_0^{(2)}: \beta_1 = \beta_2 = \beta_3 = \beta_4 = 0$$

$H_1^{(2)}$: לפחות אחד מה β_j שונה מאפס:

ii. סטטיסטי המבחן

לכל גורם יש סטטיסטי F נפרד:

$$F_{\text{poison}} = \frac{MS_{\text{poison}}}{MS_W} \sim_{H_0} F(\alpha - 1, N - a - b + 1) = F(2, 42)$$

$$F_{\text{treat}} = \frac{MS_{\text{treat}}}{MS_W} \sim_{H_0} F(\alpha - 1, N - a - b + 1) = F(3, 42)$$

כאשר $a = 3$ (רמות רעל), $b = 4$ (רמות טיפול), $N = 48$ ו $N - a - b + 1 = 42$ הן דרגות החופש של השאריות.

	sum_sq	df	F	PR(>F)
C(poison)	1.0330	2.0000	20.6433	0.0000
C(treat)	0.9212	3.0000	12.2727	0.0000
Residual	1.0509	42.0000	NaN	NaN

iii. מדדי טיב התאמה

נציג את R^2 ואת מדדי המובהקות הכלליים של המודל.

	Value
R^2	0.6503
Adjusted R^2	0.6087
Global F	15.6209
Global p-value	0.0000

iv. סיכום הממצאים

- אפקט רעל: $F(2,42) \approx 20.64$, $p \approx 5.7 \cdot 10^{-7}$, מובהק מאוד. דוחים את $H_0^{(1)}$
- אפקט טיפול: $F(3,42) \approx 12.27$, $p \approx 6.7 \cdot 10^{-6}$, מובהק מאוד. דוחים את $H_0^{(2)}$
- $R^2 \approx 0.65$ המודל מסביר כ-65% מהשונות בזמני התגובה.

מסקנה: שני הגורמים (רעל וטיפול) תורמים מובהקית להסברת השונות בזמן התגובה. בסעיף ד נציג את המודל בצורת רגרסיה, ובסעיף ה נשווה את הממצאים.

ד. מודל רגרסיה מקביל

ניתן לכתוב את אותו מודל מסעיף ב (ANOVA דו-כיווני ללא אינטראקציה) באמצעות משתני דאמי. נגדיר את קבוצת הייחוס: רעל=I, טיפול=A.

i. משתני הדאמי

עבור רעל (3 רמות $\rightarrow$ 2 דאמיים):

- $D_2 = 1$ אם רעל II אחרת 0

- $D_3 = 1$ אם רעל III אחרת 0

עבור טיפול (4 רמות $\rightarrow$ 3 דאמיים):

- $T_B = 1$ אם הטיפול B אחרת 0

- $T_C = 1$ אם הטיפול C אחרת 0

- $T_D = 1$ אם הטיפול D אחרת 0

ii. המודל

$$y = \beta_0 + \beta_1 D_2 + \beta_2 D_3 + \beta_3 T_B + \beta_4 T_C + \beta_5 T_D + \epsilon$$

iii. פירוש המקדמים

- β_0 התוחלת בתא הייחוס (Poison=I, Treatment=A)

- β_1, β_2 הפרש בין רעל II, III לעומת I

- $\beta_3, \beta_4, \beta_5$ הפרש בין טיפול B, C, D לעומת A

זהות להנחות מודל ה ANOVA בסעיף ב

- נורמליות $\epsilon \sim N(0, \sigma^2)$
 - שוויון שונות $\text{Var}(\epsilon) = \sigma^2$ קבוע בכל 12 התאים
 - אי-תלות — תצפיות שונות בלתי תלויות
 - אדיטיביות — האפקטים של רעל וטיפול מצטברים, ללא אינטראקציה
- שני המודלים (ANOVA) ורגרסיה (הם הצגות שקולות מתמטית של אותה בעיה.
- ה. אמידת מודל הרגרסיה והשוואה לסעיף ג
- נריץ את מודל הרגרסיה שהגדרנו בסעיף ד, עם רעל I וטיפול A כקבוצות הייחוס:

OLS Regression Results							
Dep. Variable:	time	R-squared:	0.650				
Model:	OLS	Adj. R-squared:	0.609				
Method:	Least Squares	F-statistic:	15.62				
Date:	Sun, 19 Apr 2026	Prob (F-statistic):	1.12e-08				
Time:	08:17:23	Log-Likelihood:	23.609				
No. Observations:	48	AIC:	-35.22				
Df Residuals:	42	BIC:	-23.99				
Df Model:	5						
Covariance Type:	nonrobust						
		coef	std err	t	P> t	[0.025	0.975]
Intercept		0.4523	0.056	8.088	0.000	0.339	0.565
C(poison, Treatment(reference="I"))[T.II]		-0.0731	0.056	-1.308	0.198	-0.186	0.040
C(poison, Treatment(reference="I"))[T.III]		-0.3413	0.056	-6.102	0.000	-0.454	-0.228
C(treat, Treatment(reference="A"))[T.B]		0.3625	0.065	5.614	0.000	0.232	0.493
C(treat, Treatment(reference="A"))[T.C]		0.0783	0.065	1.213	0.232	-0.052	0.209
C(treat, Treatment(reference="A"))[T.D]		0.2200	0.065	3.407	0.001	0.090	0.350
Omnibus:	15.712	Durbin-Watson:		2.443			
Prob(Omnibus):	0.000	Jarque-Bera (JB):		19.455			
Skew:	1.154	Prob(JB):		5.96e-05			
Kurtosis:	5.099	Cond. No.		5.35			

i. המשוואה האמודה

לאחר ההצבה של המקדמים שאמדנו במודל הכללי מסעיף ד:

$$\hat{y} = 0.452 - 0.073D_{II} - 0.341D_{III} + 0.363T_B + 0.078T_C + 0.220T_D$$

ii. פירוש המקדמים

- Intercept ≈ 0.452 התוחלת בתא $0(\text{Poison}=I, \text{Treatment}=A)$
- $C(\text{poison})[T. III] \approx -0.341$ רעל III מקטין את זמן התגובה ב-0.341 שניות לעומת רעל I (מובהק).
- $C(\text{poison})[T. II] \approx -0.073$ רעל II מקטין במעט (לא מובהק $p \approx 0.20$).
- $C(\text{treat})[T. B] \approx +0.363$ טיפול B מאריך את זמן התגובה ב-0.363 לעומת A (מובהק).
- $C(\text{treat})[T. D] \approx +0.220$ טיפול D מאריך לעומת A (מובהק).
- $C(\text{treat})[T. C] \approx +0.078$ לא מובהק.

iii. השוואה לסעיף ג

- $R^2 = 0.65$ זהה למדויק לסעיף ג. שני המודלים מסבירים 65% מהשונות.
- F הגלובלי של המודל הרגרסיוני ($F(5,42) \approx 15.62, p \approx 1.1 \cdot 10^{-8}$) בודק את כל 5 המקדמים יחד – שזה לא בדיוק אותו דבר כמו ה- F הנפרדים בסעיף ג, אבל מאשר את אותה תמונה כללית.
- ה- F הנפרד של רעל ($F(2,42) = 20.64$) מסעיף ג שקול לבדיקת ההשערה $\beta_1 = \beta_2 = 0$ במודל הרגרסיה. ה- $F(3,42) = 12.27$ שקול לבדיקת $\beta_3 = \beta_4 = \beta_5 = 0$.


iv. מסקנה

מודל הרגרסיה ומודל ה-ANOVA הם הצגות שקולות מתמטית של אותה בעיה. הם מחזירים אותו R^2 , אותם אומדני ממוצעים, ואותן מסקנות על מובהקות הגורמים. ההבדל הוא בעיקר בצורת ההצגה: הרגרסיה נותנת מקדמים פרטניים עם פירוש ישיר (הפרשים מקבוצת הייחוס), בעוד שה-ANOVA מסכם כל גורם ל- F יחיד.

ו. בדיקת הנחות המודל גרפית

לאחר אמידת המודל, נבחן ויזואלית האם הנחותיו מתקיימות. נשתמש בארבעה גרפים סטנדרטיים:

- Residuals vs Fitted — בדיקת שוויון שונויות ולינאריות.
- Normal Q-Q Plot — בדיקת נורמליות של השאריות.
- Scale-Location — אישוש נוסף לשוויון שונויות.
- היסטוגרמת השאריות — צורת התפלגות השאריות.



i. מבחן Shapiro-Wilk על השאריות

תוספת פורמלית לבדיקת נורמליות:

	Value
Shapiro-Wilk W	0.9224
p-value	0.0036
Normality holds?	False

- שוויון שונויות (Residuals vs Fitted, Scale-Location): רואים דפוס "מגאפון" ברור — פיזור השאריות גדל עם הערכים החזויים. הנחת ההומוסקדסטיות מופרת בבירור. זו עדות חזקה ל Heteroscedasticity, בעקביות עם מה שזיהינו ב Box-Plots בסעיף א.

- **נורמליות (Q-Q Plot, היסטוגרמה, Shapiro):** ה Q-Q plot מראה סטיות מקו 45° בקצוות, ההיסטוגרמה אסימטרית ימנית, ו Shapiro דוחה נורמליות ($p < 0.05$). **הנחת הנורמליות מופרת.**
- אי-תלות: אין דפוס שיטתי של השאריות סביב הקו האפס שמעיד על מתאם — הנחה זו סבירה.
- אדיטיביות (אי-אינטראקציה): מהגרף של Residuals vs Fitted לא רואים דפוס לא-לינארי ברור, אך הקבוצות עם ערכים חזויים גבוהים מציגות שונות גדולה יותר — מצב שלעיתים מצביע על אינטראקציה.

iii. מסקנה

שתיים מההנחות החשובות של המודל הקלאסי מופרות: שוויון שונויות ונורמליות. למרות זאת, בגלל שהמדגם מאוזן ולא קטן ($n = 48$), ANOVA יחסית עמיד להפרות אלו, והתוצאות מסעיף ג' עדיין מספקות אינדיקציה איכותית.

לטיפול מעמיק בבעיה — נהוג להפעיל טרנספורמציה הופכית $\left(\frac{1}{y}\right)$ על זמן התגובה, מה שמייצב את השונות עבור משתנים חיוביים מסוג "זמן עד אירוע". טרנספורמציה זו לא נדרשת בשאלה אך חשוב להכיר אותה כפתרון הקלאסי לבעיה הזו.

ז. פוסט-הוק עם FDR, Fisher LSD, Bonferroni

מבחן ה ANOVA בסעיף ג אישר ששני הגורמים — רעל וטיפול — מובהקים. עתה נבדוק בין אילו רמות בכל גורם קיים הבדל מובהק.

נחזור על שלושת התיקונים שראינו בשאלה 3:

- **Fisher's LSD — t-test** רגיל, ללא תיקון. חזק אך לא שולט ב FWER.
- **Bonferroni** — מכפיל ערכי p במספר ההשוואות. שומר על FWER אך שמרני.
- **FDR (BH)** — שולט בפרופורציית גילויים שגויים. ביניים.

חשוב לציין: התיקונים מתבצעים על כל גורם בנפרד 3 — השוואות לרעלים 6, השוואות לטיפולים.

i. פוסט-הוק לגורם רעל (3 השוואות זוגיות)

Pair	LSD	Bonferroni	FDR	LSD rej	Bonf rej	FDR rej
I vs II	0.4193	1.0000	0.4193	False	False	False
I vs III	0.0000	0.0000	0.0000	True	True	True
II vs III	0.0011	0.0032	0.0016	True	True	True

ii. פוסט-הוק לגורם טיפול (6 השוואות זוגיות)

Pair	LSD	Bonferroni	FDR	LSD rej	Bonf rej	FDR rej
A vs B	0.0012	0.0070	0.0070	True	True	True
A vs C	0.1798	1.0000	0.2157	False	False	False
A vs D	0.0047	0.0280	0.0140	True	True	True
B vs C	0.0125	0.0748	0.0249	True	False	True
B vs D	0.2174	1.0000	0.2174	False	False	False
C vs D	0.0890	0.5338	0.1334	False	False	False

iii. סיכום הממצאים

רעלים:

- I vs II - לא מובהק באף שיטה ($p \approx 0.42$). הרעלים I ו II דומים בזמני התגובה שהם מייצרים.
- I vs III ו II vs III - מובהקים בכל השיטות. רעל III שונה מהותית משני הרעלים האחרים.

טיפולים:

- A vs B ו A vs D מובהקים בכל שלוש השיטות.
- B vs C דוגמה מעניינת להבדל בין השיטות: LSD ו FDR דוחים ($p \approx 0.013, 0.025$), אך Bonferroni לא ($p \approx 0.075$).

- A vs C, B vs D, C vs D לא מובהקים באף שיטה.

iv. השוואה בין השיטות

ההבדל בין השיטות בולט בעיקר בזוגות "גבוליים":

- **Bonferroni** מבטל ממצאים גבוליים (כמו B vs C) שמרני וזהיר.
- FDR משמר אותם מאזן בין כוח ושליטה בטעויות.
- LSD משמר אותם מאזן בין כוח ושליטה בטעויות.

מסקנה: רעל III גורם לזמני תגובה שונים מובהקית מ I ו II. קרב הטיפולים, A מובהקית שונה מ B ומ D, וייתכן הבדל גם בין B ל C (תלוי בשיטת התיקון). הבחירה בין השיטות תלויה בהקשר **Bonferroni** למסקנות בטוחות, FDR למחקר חקרני.

5. להלן נתונים שנאספו ממחקר פורץ דרך על הקשר בין x ל y

$$\bar{x} = 5$$

$$\bar{y} = 3$$

$$n = 20$$

$$\sum (x_i - \bar{x})^2 = 160$$

$$\sum (y_i - \bar{y})^2 = 83.2$$

$$\sum (x_i - \bar{x})(y_i - \bar{y}) = 80$$

החוקרים הניחו כי המודל הבא מתאר באופן מדויק את הקשר בין x ל y:

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i$$

א. אמידת משוואת הרגרסיה

i. הנוסחאות

האומדים של פרמטרי הרגרסיה הליניארית הפשוטה:

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \cdot \bar{x}$$

ii. הצבה

$$\hat{\beta}_1 = \frac{80}{160} = 0.5$$

$$\hat{\beta}_0 = 3 - 0.5 \cdot 5 = 0.5$$

iii. משוואת הרגרסיה

$$\hat{y} = 0.5 + 0.5x$$

פירוש: לכל יחידה ש x עולה, התחזית של y עולה ב-0.5.

	Value
$\hat{\beta}_0$ (intercept)	0.5000
$\hat{\beta}_1$ (slope)	0.5000
Regression equation	$\hat{y} = 0.5 + 0.5 \cdot x$

ב. טבלת ANOVA ובחינת מובהקות המודל

i. השערות המבחן

$$H_0 : \beta_1 = 0$$

$$H_1 : \beta_1 \neq 0$$

ii. סטטיסטי המבחן

$$F_s = \frac{MS_{Reg}}{MS_{Res}} \sim H_0 F(1, n - 2) = F(1, 18)$$

iii. חישוב סכומי הריבועים

$$SS_T = S_{yy} = 83.2 \quad \bullet$$

$$SS_{Reg} = \hat{\beta}_1 \cdot S_{xy} = 0.5 \cdot 80 = 40 \quad \bullet$$

$$SS_{Res} = SS_T - SS_{Reg} = 83.2 - 40 = 43.2 \quad \bullet$$

iv. ממוצעים ריבועיים

$$MS_{Reg} = \frac{SS_{Reg}}{df_{Reg}} = \frac{40}{1} = 40 \quad \bullet$$

$$MS_{Res} = \frac{SS_{Res}}{df_{Res}} = \frac{43.2}{18} = 2.4 \quad \bullet$$

v. סטטיסטי F

$$F_s = \frac{40}{2.4} \approx 16.67$$

	df	SS	MS	F	p-value
Regression	1	40.0000	40.0000	16.6667	0.0007
Residual	18	43.2000	2.4000	NaN	NaN
Total	19	83.2000	NaN	NaN	NaN

vi. ערך קריטי p-value ו R^2

	Value
F_s	16.6667
F_c ($\alpha=0.05$)	4.4139
p-value	0.0007
R^2	0.4808
Reject H_0 ?	True

$$F_s \approx 16.67 > F_c \approx 4.41$$

$$p - value \approx 0.0007 < \alpha = 0.05$$

מאחר שהסטטיסטי עבר את הערך הקריטי (וה $p - value$ קטן מ α), דוחים את H_0 קיים קשר ליניארי מובהק

בין x ל y .

$R^2 \approx 0.481$ המודל מסביר כ-48% מהשונות ב y .